AulaConTexto

Informe de uso de inteligencia artificial y de evaluación del prototipo con agentes de IA

Karen Buitrago · Andrés Cañón · Nicolás Mora

Seminario de Investigación · Ingeniería de Sistemas · Universidad El Bosque

Bogotá, 9 de noviembre de 2026

Repositorio público y prototipo navegable: https://github.com/havo-ao/aulacontexto · prototipo: https://havo-ao.github.io/aulacontexto/

1. Alcance de este informe

Este informe acompaña la entrega del prototipo navegable de AulaConTexto. Documenta (a) cómo, por qué y para qué se usó inteligencia artificial en el diseño y construcción del prototipo, con los prompts y el flujo de trabajo empleados, y (b) la evaluación de usabilidad de la primera versión, realizada con tres agentes de IA que encarnan perfiles de usuario, con su instrumento, método, resultados, evidencia y límites. El prototipo es de alta fidelidad visual y sin backend: la generación de texto está simulada a partir del contexto del curso.

La evaluación no se hizo con docentes reales. El acceso a docentes y coordinadores del colegio no fue posible en el plazo de la entrega, por lo que el equipo optó por una evaluación con agentes de IA, declarada como tal en todos los entregables. La prueba con docentes está programada para el sprint 0 de Proyecto de Grado I con el mismo instrumento.

2. Uso de inteligencia artificial

2.1 Herramientas

Herramienta	Uso	Revisión humana
Claude Code (Anthropic), modelo Claude	Generación de conceptos visuales, construcción de los prototipos v1 y v2 en HTML/CSS/JS, revisión heurística, agentes que encarnan perfiles de usuario para la evaluación, redacción de informes y de este documento	El equipo revisó y ajustó cada salida antes de adoptarla; las decisiones de diseño y de alcance fueron del equipo
draw.io (diagrams.net)	Diagramas de arquitectura, secuencia, datos y cronograma, generados como archivos .drawio editables	Verificación visual de cada diagrama y corrección de enrutamientos
Google Chrome sin interfaz	Capturas de pantalla del prototipo y exportación de PDF	—
Microsoft Word	Exportación de los documentos a PDF	—
GitHub	Repositorio público con historial por hitos y publicación del prototipo en GitHub Pages	—

2.2 Flujo de trabajo con IA

El trabajo siguió un ciclo fijo: el equipo formula un prompt con el contexto del proyecto; la IA propone; el equipo revisa, decide y pide ajustes; la salida aceptada se integra y se registra. Ninguna salida se adoptó sin revisión. El ciclo se aplicó en seis etapas:

1. Exploración de alternativas: cuatro conceptos visuales distintos, con la restricción explícita de evitar interfaces genéricas de tipo chat, Notion, CRM o panel administrativo.
2. Construcción del prototipo v1 sobre el concepto elegido («Aula digital»).
3. Evaluación: revisión heurística desde el rol de diseñador senior y entrevistas de usabilidad con tres agentes de IA, cada uno encarnando un perfil de usuario, sobre el código de la versión 1.

4. Iteración: tres versiones de rediseño con justificación, ventajas y riesgos; implementación de la elegida en el prototipo v2.
5. Ampliación de la v2 con los hallazgos de las entrevistas: inicio de sesión por rol, carga de archivos, tres tipos de generación, historial de versiones, exportación, observaciones del docente en la retroalimentación y vista de coordinación con trazabilidad.
6. Panel de inicio tipo dashboard: fichas de pizarrón con indicadores, tarjetas por curso, pendientes, actividad reciente y avance de validación; resumen por curso en coordinación.

2.3 Prompts utilizados

Se transcriben los prompts principales. Los textos completos y las respuestas están en el historial de la sesión; se omiten reiteraciones menores de ajuste.

Prompt 1 · Conceptos visuales

> *Vamos a construir el prototipo navegable de AulaConTexto. No generes todavía código. Primero quiero explorar alternativas de diseño. [Contexto del producto y flujo de seis pasos.] Propón 4 conceptos visuales completamente diferentes con: nombre, concepto, inspiración visual, paleta, tipografía, componentes distintivos, ventajas. No quiero dashboards SaaS genéricos. Evita diseño estilo ChatGPT, Notion, CRM o administrativo. Al menos una propuesta debe parecer una mesa de trabajo pedagógica, una libreta inteligente, un aula digital y una herramienta de diseño creativo para docentes.*

Prompt 2 · Revisión UX

> *Actúa como UX Designer Senior de Duolingo, Canva y Notion. Revisa el prototipo actual. Identifica problemas visuales, elementos genéricos, componentes débiles y oportunidades de diferenciación. Propón mejoras visuales específicas para AulaConTexto. No reescribas código aún. Presenta primero las recomendaciones.*

Prompt 3 · Agente de evaluación (uno por perfil; se muestra el de P1)

> *Eres un agente de evaluación de usabilidad que encarna a una PERSONA de usuario. Tu tarea es recorrer un prototipo web y producir una transcripción de prueba de usabilidad realista, en español, desde la perspectiva de esa persona. PERSONA (P1): Gloria, 52 años, docente de primaria (3.º y 4.º) en un colegio público de Bogotá, 26 años de experiencia. [Hábitos y afinidad tecnológica.] PROTOTIPO: lee con atención el archivo prototipo-v1.html. Reconstruye desde el código qué ve el usuario en cada pantalla: textos exactos de botones, etiquetas, modales, pasos del asistente, estados, mensajes. Basa TODO lo que la persona dice en lo que realmente existe en ese código; no inventes pantallas ni botones. PROTOCOLO (sesión moderada, pensamiento en voz alta): T1 crear un curso nuevo con grado y asignatura; T2 subir un material y dejarlo marcado para que la IA lo use; T3 generar un plan de clase; T4 revisar el borrador, editar una frase y aprobarlo. Luego cuestionario SUS (10 ítems, escala 1–5) y 4 preguntas abiertas. Sé realista: esta persona debe tener dificultades verosímiles con este prototipo concreto. No hagas que todo salga bien ni que todo salga mal. ENTREGA en Markdown con esta estructura: datos de la sesión; transcripción por tarea (resultado, citas textuales de la interfaz entre «», observación del moderador); cuestionario SUS con fórmula; preguntas abiertas; síntesis del moderador con severidad.*

Prompt 4 · Iteración

> *Tomando los hallazgos de los 3 usuarios, rediseña el flujo principal: subir contenido de una clase → generar material con IA → revisar resultado. Prioridades: menos pasos, menos formularios, menos carga cognitiva, más claridad visual, mejor feedback durante el procesamiento. Analiza UX, arquitectura de información, jerarquía visual, microinteracciones y llamadas a la acción. Genera Versión A, B y C con justificación, ventajas y riesgos.*

Prompt 5 · Ampliación de la v2

Ayúdame a mejorar el v2 del prototipo, porque está muy sencillo. [Se incorporaron los hallazgos de las tres entrevistas: trazabilidad de aprobación, lectura y filtros en coordinación, carga de archivos, historial de versiones, confirmación al aprobar y grados de primaria.]

Prompt 6 · Panel de inicio

Se ve muy bonito, pero quiero que se vea como un dashboard. Ayúdame a crearlo y dejarlo listo publicado en el prototipo v2. Mantén la idea de los colores y diseño como de pizarrón. Siento que debería haber más cuadritos en vez de solo texto.

2.4 Habilidades (skills) y configuración

Se usaron las guías de diseño de artefactos del asistente para la presentación HTML, la guía de documentos Word para los informes, la ejecución de agentes en paralelo para las tres entrevistas, y la capacidad de ejecutar herramientas locales (navegador sin interfaz, draw.io, Git) para capturas, exportaciones y control de versiones. No se entrenó ni ajustó ningún modelo; no se enviaron datos personales de estudiantes ni de docentes al asistente.

2.5 Resultado y límites

El uso de IA permitió recorrer en una semana el ciclo concepto → prototipo → evaluación → iteración → ampliación, con dos versiones navegables, un panel de inicio, un informe de diseño y tres entrevistas documentadas. Sus límites se declaran expresamente: la revisión heurística y las entrevistas son producto de agentes de IA que razonan sobre el código de la interfaz y sobre la literatura de adopción docente; no sustituyen la prueba con docentes reales. Los puntajes SUS de la sección 3 describen la percepción de los agentes y no se interpretan como medidas de usabilidad con personas.

3. Evaluación de usabilidad con agentes de IA

3.1 Método

Se realizaron tres entrevistas de usabilidad en las que el participante fue un agente de IA (modelo Claude) instruido para encarnar un perfil de usuario definido por el equipo. Cada agente recibió el código fuente completo del prototipo v1, la descripción de su perfil y el protocolo de la sesión, con la instrucción de basar cada acción y cada cita en elementos que existen en la interfaz y de no inventar pantallas ni botones. Los tres agentes trabajaron en paralelo y de forma independiente, sin acceso a las respuestas de los demás.

El uso de modelos de lenguaje como participantes sintéticos en estudios de interacción humano-computador está documentado en la literatura reciente: Hämäläinen, Tavast y Kunnari (2023) evaluaron la generación de datos sintéticos de investigación en HCI, y Park et al. (2023) mostraron agentes generativos con comportamiento verosímil. Ambos trabajos señalan la misma limitación que asume este informe: los agentes producen hipótesis plausibles, no evidencia de campo.

Verificación. El equipo contrastó cada transcripción con el prototipo v1 y comprobó que los textos citados entre comillas angulares («») corresponden a etiquetas, botones y mensajes reales de la interfaz, y que las dificultades reportadas se explican por el comportamiento del código (por ejemplo, el estado «en uso» de un material dependía de un clic sin señal visible; la regeneración creaba una hoja nueva sin conservar ediciones). Los tiempos por tarea que aparecen en las transcripciones son estimaciones del agente y no se usan como medida.

3.2 Instrumento

Sesión moderada con pensamiento en voz alta. Tareas del docente (P1, P2) y de coordinación (P3), cuestionario SUS (System Usability Scale, Brooke, 1996) de diez ítems en escala de 1 a 5 y cuatro preguntas abiertas.

Tarea	Descripción	Éxito
T1	Crear un curso nuevo con su grado y asignatura	Curso visible en la lista
T2	Subir un material y dejarlo marcado para que la IA lo use	Material en estado «en uso»
T3	Generar un plan de clase para la unidad	Borrador en pantalla
T4	Revisar el borrador, editar una frase y aprobarlo	Plan aprobado con la edición conservada
T5	(Coordinación) Encontrar y leer un plan aprobado	Plan completo visible desde la vista de coordinación
T6	(Coordinación) Verificar quién aprobó el plan y cuándo	Autor y fecha identificados
T7	(Coordinación) Observar la generación de una retroalimentación y evaluar la protección de datos del estudiante	Juicio fundamentado sobre alias, materiales y destino de los datos

Preguntas abiertas. (1) ¿Qué le resultó más claro y qué más confuso? (2) ¿Confiaría en entregar a sus estudiantes una retroalimentación generada tras revisarla? ¿Por qué? (3) ¿Qué información necesita ver antes de aprobar (o, para coordinación, qué necesita ver en su vista)? (4) ¿Qué cambiaría del tablero de contexto?

3.3 Perfiles

	Perfil	Descripción dada al agente
P1	Docente de primaria	Gloria, 52 años, docente de 3.º y 4.º en colegio público de Bogotá, 26 años de experiencia. Planea en plantilla de Word, califica a mano. Baja afinidad tecnológica; no usa IA generativa.
P2	Docente universitario	Daniel, 38 años, profesor de programación en ingeniería. Evalúa con rúbricas en Moodle; usa ChatGPT y Copilot a diario. Perfil crítico y directo.
P3	Coordinadora académica	Marcela, coordinadora de un colegio de Bogotá. Revisa planes de área y responde ante rectoría por lo que se publica a los estudiantes. Prioriza trazabilidad y protección de datos.

3.4 Resultados por tarea y SUS

Perfil	T1	T2	T3	T4	T5	T6	T7	SUS
P1 · Primaria	Con ayuda	Con ayuda	OK	Con ayuda	—	—	—	50
P2 · Universitario	OK	Con ayuda	OK	OK*	—	—	—	67,5
P3 · Coordinación	—	—	—	—	Parcial	Falló	Con ayuda	62,5

* Completada con pérdida de la edición al regenerar. Promedio SUS de los tres agentes: 60, por debajo de la referencia de 68. Los tres coinciden en que la metáfora del aula se entiende de inmediato (ítems 3 y 7 altos) y en una baja sensación de seguridad (ítem 9 = 2 en los tres casos), por motivos distintos:

publicación sin aviso (P1), pérdida de ediciones y opacidad del contexto (P2) y ausencia de autor, fecha y destino de los datos (P3).

#	Ítem SUS	P1	P2	P3
1	Me gustaría usar este sistema con frecuencia	3	3	3
2	El sistema es innecesariamente complejo	3	2	2
3	El sistema es fácil de usar	3	4	4
4	Necesitaría apoyo técnico para usarlo	4	1	2
5	Las funciones están bien integradas	4	3	2
6	Hay demasiada inconsistencia	2	3	3
7	La mayoría aprendería a usarlo rápido	3	4	4
8	Es engorroso de usar	3	2	2
9	Me sentí seguro(a) usándolo	2	2	2
10	Necesité aprender muchas cosas antes de empezar	3	1	1
	Puntaje SUS (0–100)	50	67,5	62,5

3.5 Hallazgos consolidados y cambios aplicados en la v2

#	Hallazgo (v1)	Perfiles	Severidad	Cambio en v2
H1	Marcar un material «en uso» exige un clic sin señal visible; subir no equivale a usar	P1, P2	Alta	Chips con ✓/+; al agregar un material queda marcado
H2	Regenerar borra las ediciones del docente sin aviso	P2	Alta	Guardado automático, regeneración por bloque e historial de versiones consultable
H3	Sin trazabilidad de aprobación: no se registra autor ni fecha	P3	Alta	Autor, fecha y hora en cada aprobación; tabla en la vista de coordinación
H4	La vista de coordinación lista títulos pero no abre el contenido ni filtra	P3	Alta	Lectura completa del documento, filtros por curso y tipo, buscador y métricas
H5	El selector de grado solo ofrece 6.º–11.º y «Editar contexto» no está implementado	P1, P2	Alta	Grados 1.º a 11.º; unidad, objetivos, temas y rúbrica editables en el tablero
H6	El texto editable no se anuncia hasta hacer clic	P1	Alta	Leyenda visible en la cabecera e instrucción «clic en un bloque para editar»
H7	«Aprobar» publica a coordinación sin confirmación	P1, P2, P3	Media	Confirmación previa que indica quién verá el documento
H8	El panel «Contexto usado» muestra solo conteos	P2	Media	Panel con materiales por nombre y tratamiento de datos; los fragmentos exactos quedan pendientes
H9	La retroalimentación repite el mismo párrafo en los cuatro criterios	P3	Media	Texto distinto por criterio con referencia al trabajo; el docente

#	Hallazgo (v1)	Perfiles	Severidad	Cambio en v2
				elige el trabajo y agrega sus observaciones, que se incorporan al borrador
H10	Contenido plantilla no contextualizado y errores de concordancia en el objetivo	P1, P2	Media	Fragmentos del material cargado en el borrador; redacción corregida
H11	Solo se puede pegar texto; no se adjuntan archivos	P1, P2	Media	Arrastrar archivos .txt o .md con lectura del contenido
H12	El modal «Generar» repite el contexto y el procesamiento no informa	P1, P2	Media	Tres acciones directas (plan, taller, retroalimentación); cinco etapas con tiempo estimado y cancelar

Pendientes para Proyecto de Grado I, señalados por los agentes y fuera del alcance de la v2: un paso de revisión por coordinación distinto de la aprobación del docente (P3); aviso explícito sobre el destino de los datos al cargar trabajos de estudiantes (P3); duración de la sesión y nivel educativo configurables en el contexto (P2); y visualización de los fragmentos exactos enviados al modelo (P2).

Panel de inicio. Después de las entrevistas se agregó un panel de inicio para el docente, porque con varios cursos la primera pantalla debía mostrar de un vistazo qué hay pendiente antes de entrar a un aula. Se mantuvo la metáfora del aula: los indicadores son fichas de pizarrón con números en tiza, cada curso es un tablero con sus contadores, los borradores aparecen como hojas del escritorio y la actividad reciente usa los mismos colores del aula (rojo pendiente, verde aprobado, violeta IA, madera materiales). Coordinación recibió las mismas fichas y un resumen por curso. Este panel no fue evaluado por los agentes; su prueba queda para el sprint 0 junto con el resto del prototipo.

3.6 Límites de la evaluación

- Los agentes razonan sobre el código y no sobre una pantalla: detectan con facilidad problemas que un usuario real podría no notar, y pueden pasar por alto dificultades perceptivas o de contexto escolar.
- Los perfiles fueron definidos por el equipo; existe riesgo de que los agentes confirmen las hipótesis implícitas en esas descripciones.
- Los puntajes SUS y los tiempos no son comparables con medidas tomadas a personas. Se reportan como percepción del agente y como insumo de priorización.
- Los hallazgos se tratan como hipótesis de diseño. Su validación con docentes y coordinación del colegio está programada para el sprint 0 de Proyecto de Grado I (febrero de 2027), con este mismo instrumento.

3.7 Evidencia

Las tres transcripciones completas (recorrido por tarea, cuestionario SUS con justificación por ítem, preguntas abiertas y síntesis del moderador) se entregan en la carpeta evidencia/ junto a este informe y en el repositorio público (prototipo/evidencia/). Las figuras siguientes corresponden al prototipo v2 publicado, incluido el panel de inicio agregado después de las entrevistas.

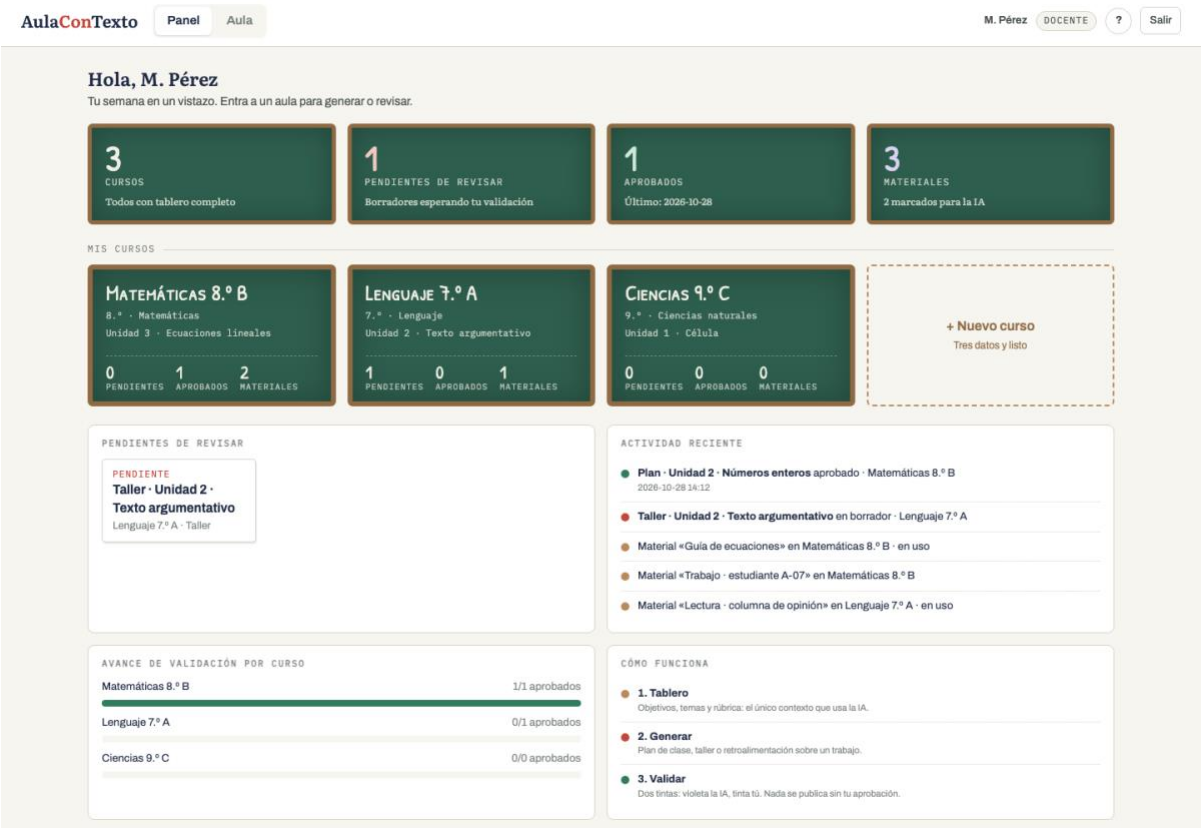


Figura 1. Panel de inicio del docente: fichas de pizarrón, tarjetas por curso, pendientes, actividad y avance de validación.

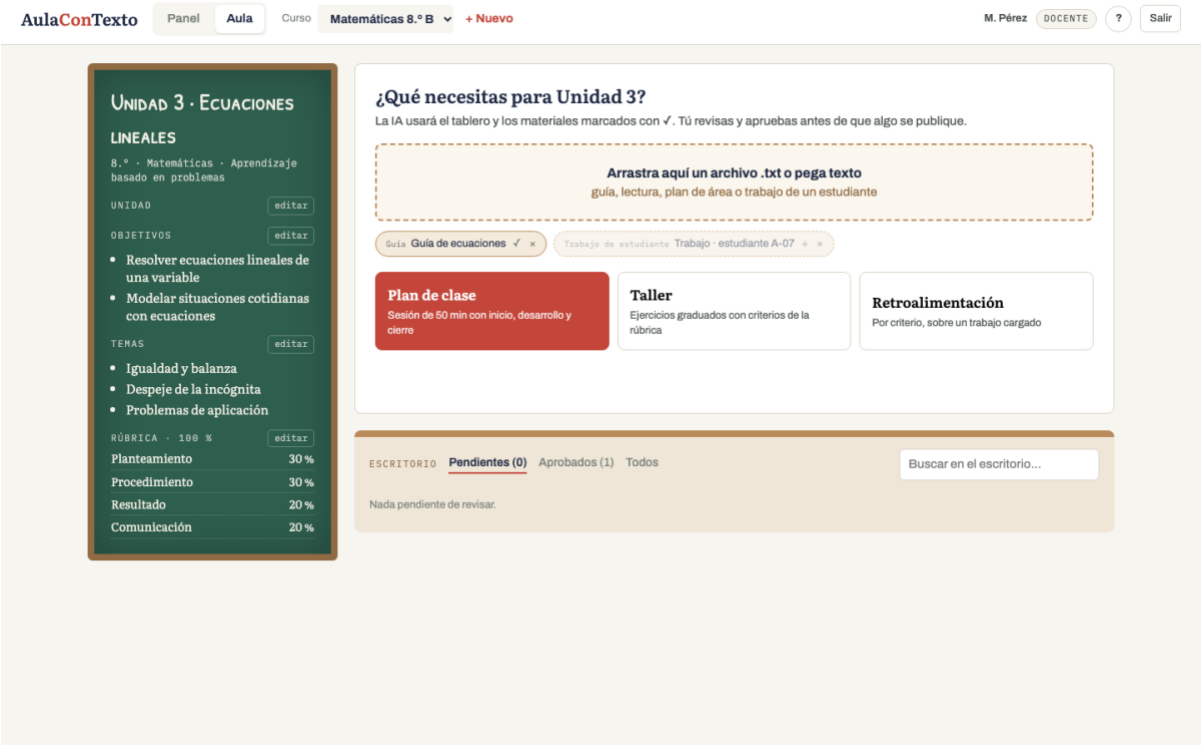


Figura 2. Aula del curso: tablero de contexto, materiales y tres tipos de generación (T2, T3).

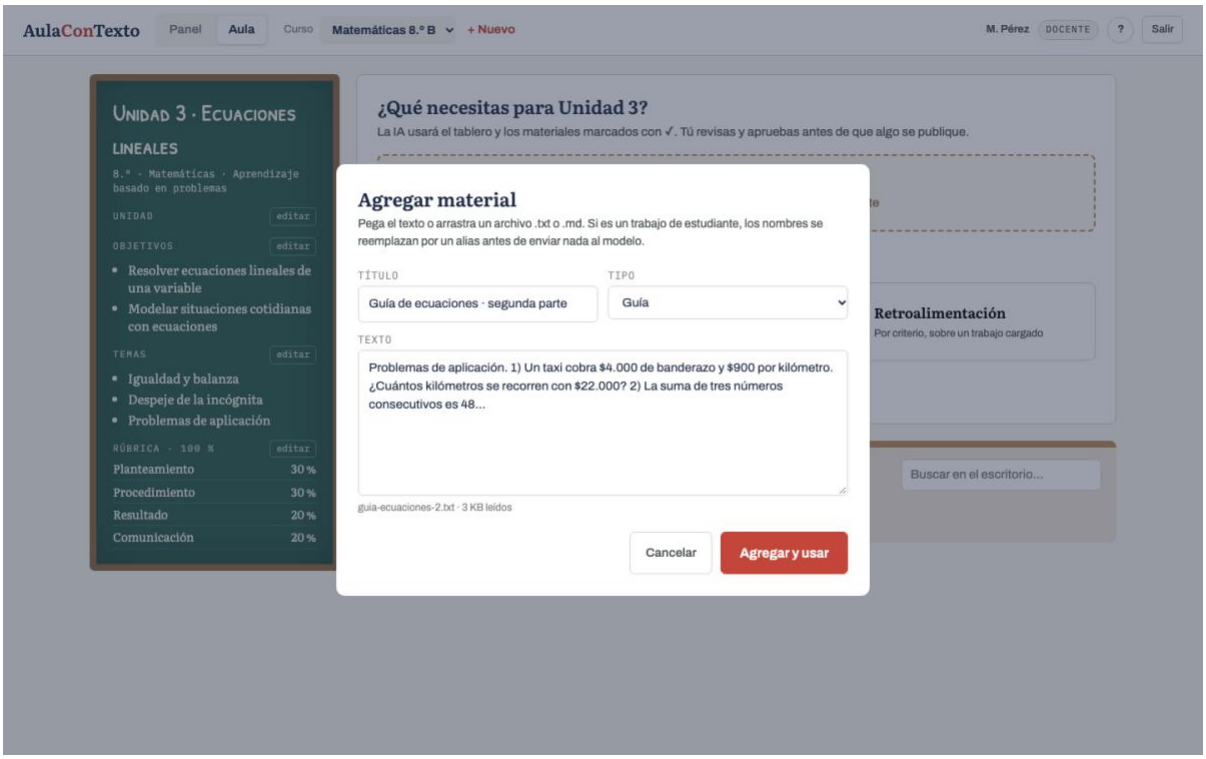


Figura 3. Carga de material por archivo o texto pegado (T2, H11).

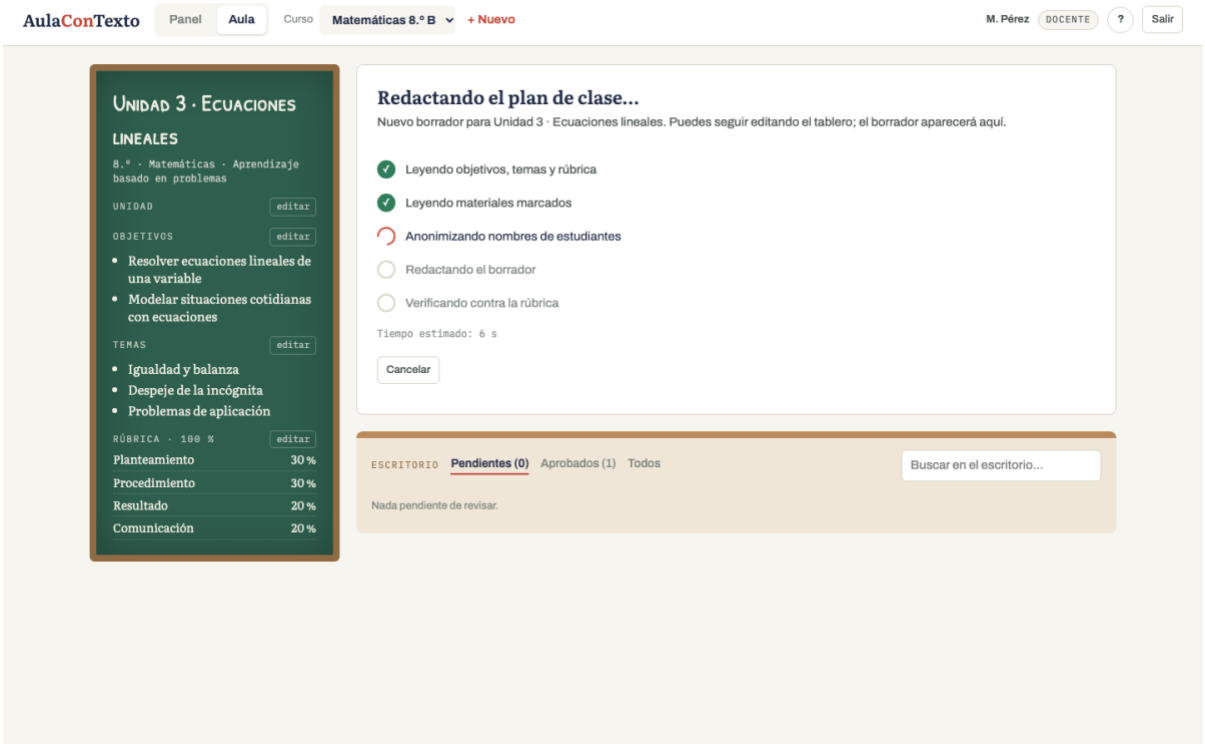


Figura 4. Progreso por etapas con anonimización y cancelación (T3, H12).

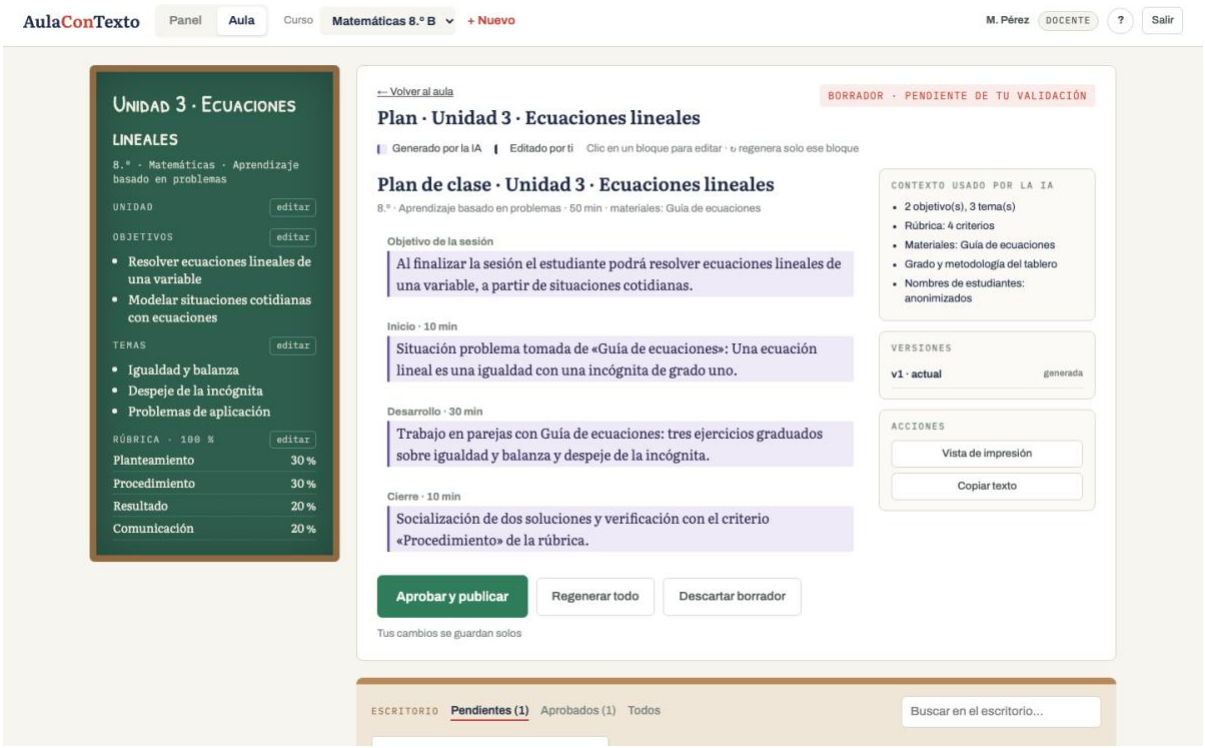


Figura 5. Borrador con dos tintas, contexto usado y versiones (T4, H2, H8).

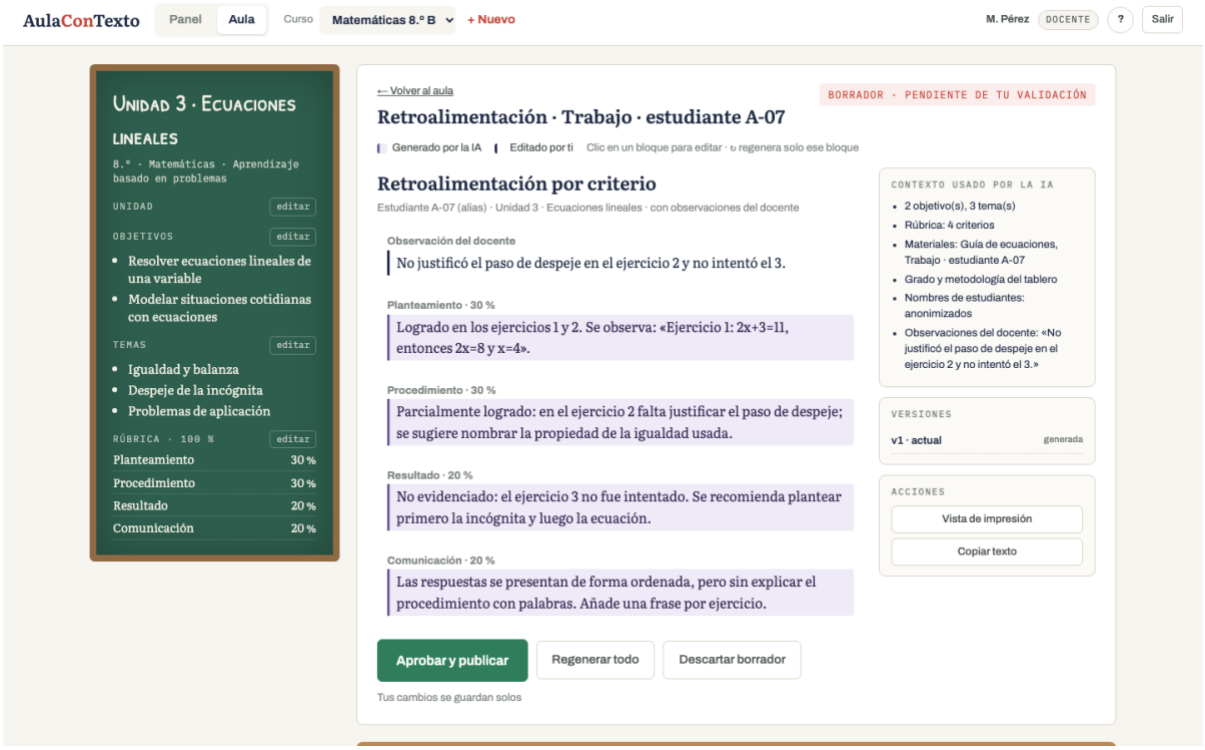


Figura 6. Retroalimentación por criterio con alias del estudiante y observación del docente (T7, H9).

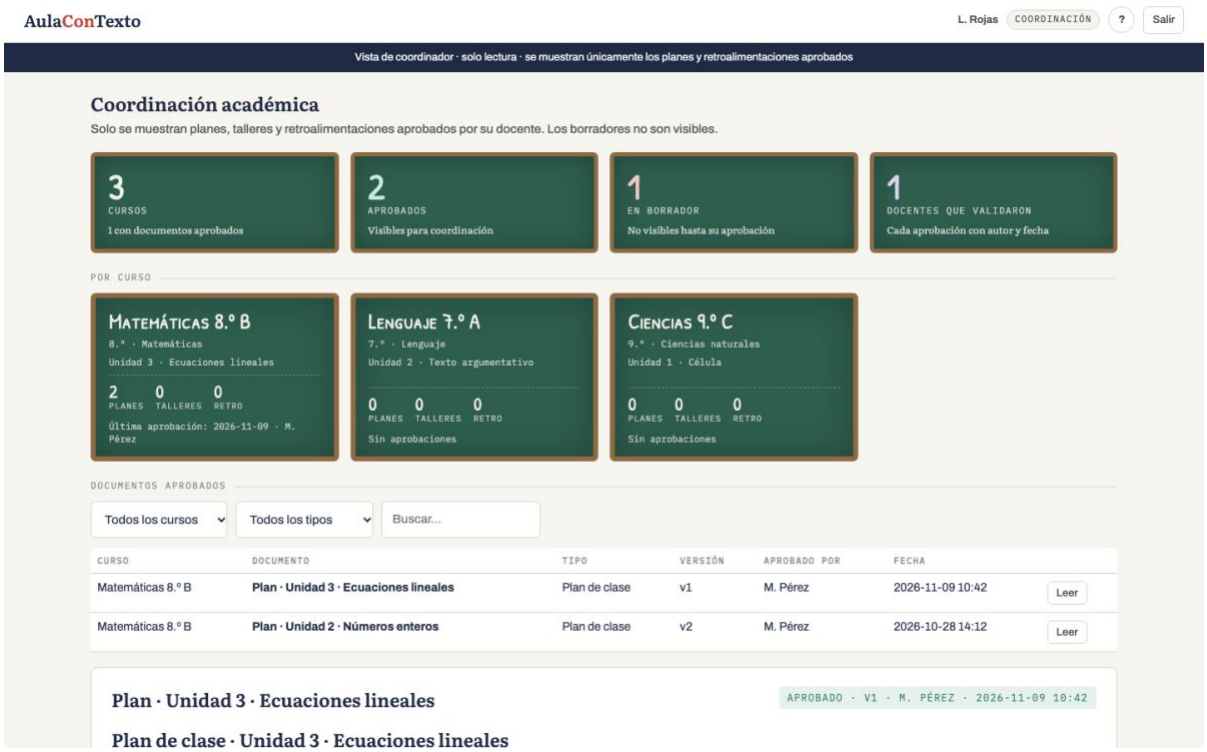


Figura 7. Vista de coordinación con fichas, resumen por curso, autor, fecha, filtros y lectura del documento (T5, T6, H3, H4).

4. Conclusiones

7. El concepto «Aula digital» comunica la tesis del proyecto sin explicación: el contexto es del docente y la validación es suya. Los tres agentes lo señalaron como lo más claro de la interfaz.
8. Los seis hallazgos de severidad alta fueron de flujo y de trazabilidad, no de estética: descubrimiento de acciones, pérdida de ediciones, autor y fecha de aprobación y lectura desde coordinación. Todos se atendieron en la v2.
9. La evaluación con agentes de IA produjo doce hallazgos específicos y verificables contra la interfaz en pocas horas y sin exponer a docentes ni datos de estudiantes. Se declara como evaluación con agentes y sus puntajes no se interpretan como usabilidad medida en personas.
10. El siguiente paso es la prueba con docentes reales en el sprint 0 de Proyecto de Grado I y la conexión del prototipo al esqueleto React, Node y MySQL del repositorio.

Referencias

[1] J. Brooke, «SUS: a quick and dirty usability scale», en Usability Evaluation in Industry, Taylor & Francis, 1996.

[2] J. Nielsen, «Heuristic evaluation», en Usability Inspection Methods, Wiley, 1994.

[3] Y. H. Cheah, J. Lu y J. Kim, «Integrating generative artificial intelligence in K-12 education», Comput. Educ. Artif. Intell., vol. 8, 100363, 2025.

[4] Q. Sun, F. Jin y L. Li, «Determinants of perceived usefulness, satisfaction and behavioral intention of using AI in lesson planning among English teachers», Front. Psychol., 2026.

[5] J. Han y M. Li, «Exploring ChatGPT-supported teacher feedback in the EFL context», System, vol. 126, 103502, 2024.

[6] P. Hämäläinen, M. Tavast y A. Kunnari, «Evaluating large language models in generating synthetic HCI research data: a case study», en Proc. CHI Conf. Human Factors in Computing Systems, ACM, 2023.

[7] J. S. Park, J. O'Brien, C. J. Cai, M. R. Morris, P. Liang y M. S. Bernstein, «Generative agents: interactive simulacra of human behavior», en Proc. ACM Symp. User Interface Software and Technology (UIST), 2023.